

Seu classificador de intenções é 12 pontos pior em português.

Medi pequenos modelos de decisão e modelos de embeddings em mensagens de atendimento em PT-BR. Depois traduzi tudo para o inglês e rodei de novo, frase a frase.

[Arraste para ver o que muda →](#)

O mesmo pipeline de um agente em produção.

1

Pré-seleção

Um modelo de embeddings (Qwen3 0.6B ou 4B) escolhe os 10 objetivos mais parecidos com a mensagem.

2

Decisão

O modelo de decisão (Laya ou Strands Decider) dá uma probabilidade para cada uma das 10 opções.

3

Combinação

Os dois sinais são combinados e calibrados; o peso de cada um é ajustado nos exemplos.

30 objetivos de atendimento · 10 exemplos cada · 150 frases de teste · 3 sementes · 50 execuções. As mesmas frases traduzidas para o inglês.

Um bom embedding sozinho venceu tudo.

94,7%

Embeddings sozinhos (Qwen3-4B)

nenhum modelo de decisão melhorou isso

85%

Strands Decider (2B)

o melhor modelo de decisão, sem ajuste

52%

Laya multilíngue

abaixo dos embeddings que deveria complementar

Acerto top-1 em 150 frases, opções em ordem aleatória, média de 3 sementes.

Decider × Laya: diferença significativa em todas as comparações (McNemar).

Em produção, a opção certa costuma vir primeiro.

As opções vão ordenadas por semelhança. Um modelo que só prefere a primeira opção parece ótimo sem ler a mensagem.

62%

das vezes o Laya escolhe a 1ª opção quando ela vem por semelhança; com a ordem invertida, perde 11 pontos

4 de 150


frases mudam de resultado no Strands Decider quando a ordem é invertida: ele lê o conteúdo

Teste sempre com as opções embaralhadas.

Nas mesmas frases, tudo acerta menos em português.

Every component is less accurate in PT-BR; the checkpoint's language matters most

Top-1 accuracy (%) on 150 paired test phrases, mean of 3 seeds, random option order. Decider-alone rows use the 0.6B shortlist.



Pipeline completo com embeddings 0.6B: –8,4 pontos.
Embeddings 0.6B: –12 pontos.

E o maior efeito do estudo: o checkpoint em inglês do Laya é 24 pontos melhor que o multilíngue. Para português, não existe checkpoint próprio.

Cinco lições para classificar objetivos em PT-BR.

1 Invista primeiro no modelo de embeddings.

Foi o melhor componente isolado nos dois idiomas.

2 Embaralhe as opções ao testar.

A ordem de produção premia quem só gosta da primeira opção.

3 Ajuste a combinação com frases separadas.

Os exemplos dos objetivos superestimam o modelo de decisão.

4 Avalie no idioma dos seus usuários.

Em inglês, todos os componentes pareceram melhores.

5 Para português, planeje um fine-tuning.

Um checkpoint por idioma valeu 24 pontos em inglês.

REPRODUZA VOCÊ MESMO

Tudo aberto: código, dados e os registros das 50 execuções.

Recalcule todos os números em cerca de um minuto, sem GPU e sem servidor de modelo.

REPOSITÓRIO

github.com/fuljorge/goal-classification-bench

DOI (ZENODO)

[10.5281/zenodo.23233352](https://doi.org/10.5281/zenodo.23233352)

POST COMPLETO

[link nos comentários](#)

Próximo experimento: fine-tuning em PT-BR. Será que fecha a diferença?